Solucio Parcia TAM 2026-2

Nombre: Alexis Andres Valencia Cembal
CC: 1088588899

① Tenemos X_{nxp} necesitamos predecir un $t_{n\,nx1}$ problema la relación $X_n \rightarrow t_n$ no siempre es lineal, para evitar esto y hacer que en un mundo de mas dimensiones la relación $X_n \leftrightarrow t_n$ sea lineal haremos

$$\phi(x) \quad x \in \mathbb{R}^{N \times Q}$$

Calculamos t_n
una buena aproximación es

$$\hat{t}_n = \phi(x_n)^T w \approx t_n$$ al ser una aproximacion hay un error

$$\eta_n = t_n - \phi(x_n)^T w$$

Donde w: Vector de pesos

Se trata de encontrar un w optimo reduciendo al minimo el error η_n

De la siguiente manera $(t_n - \phi(x_n)^T w)^2$

$$J(w) = \frac{1}{2} \sum_{n}^{N} (t_n - \phi(x_n)^T w)^2$$

$J(w)$ = funcion objetivo Suma de todos los errores $(t_n - \phi(x_n)^T w)^2$

en notacion Matricial

$$J(w) = \frac{1}{2} \|t - \phi w\|_2^2 = \frac{1}{2} (t - \phi w)^T (t - \phi w)$$

$$t \in \mathbb{R}^{N \times 1}; \quad \phi \in \mathbb{R}^{N \times Q}; \quad w \in \mathbb{R}^{Q \times 1}$$

Solucion 1.1

Dado $t_n = \phi(x_n)^T w + \eta_n \quad n = 1, \dots, N$

en la Forma matricial

$$t = w + \eta \quad \eta \in \mathbb{R}^{N \times 1}$$

$$J(w) = \frac{1}{2} (t^T - w^T \phi^T)(t - \phi w)$$

$$J(w) = \frac{1}{2} (t^T t - t^T \phi w - w^T \phi^T t + w^T \phi^T \phi w)$$

$$(t^T \phi w)^T = w^T \phi^T t$$

$$J(w) = \frac{1}{2} t^T t - w^T \phi t + \frac{1}{2} w^T \phi^T \phi w$$

Calculamos el gradiente respecto a w

Reglas del Calculo matricial

$\nabla_w (w^T a) = a$

$\nabla_w (w^T A w) = 2Aw$

$$J w = \frac{1}{2} t^T t - w^T \phi t + \frac{1}{2} w^T \phi^T \phi w$$

$$\nabla_w J(w) = 0 - \phi t + \frac{1}{2} 2 \phi^T \phi w$$

$$\nabla_w J(w) = -\phi t + \phi^T \phi w$$

$$\nabla_w J(w) = \phi^T \phi w - \phi t$$

Condicion de primer Orden

$$\nabla_w J(w) = 0_Q \qquad 0_Q \in \mathbb{R}^{Q \times 1}$$

Hallamos Puntos Criticos

$$\Phi^T \Phi w - \Phi t = 0_Q$$

$$\Phi^T \Phi w = \Phi t$$

Solucion en Forma Cerrada

Si la matriz de Covarianza de Caracteristicas $\Phi^T \Phi \in \mathbb{R}^{Q \times Q}$ es Invertible mutiplicamos Por Su Inversa $(\Phi^T \Phi)^{-1}$ Por la Izquierda

$$\hat{W}_{LS} = (\Phi^T \Phi)^{-1} \Phi^T t$$

- $\Phi^T \Phi \in \mathbb{R}^{Q \times Q}$ Invertible
- $\Phi \in \mathbb{R}^{N \times Q}$ $\text{rango}(\Phi) = Q$
- $N \geq Q$ Q columnas de Φ Sean L_I

Condicion de Segundo Orden

$$H = \nabla_w^2 = \Phi^T \Phi$$

es en minimo global unico

-

1.2 Minimos Cuadrados regularizados

$$J_{reg}(w) = \frac{1}{2}\sum_{n=1}^{N}(t_n - \phi(x_n)^T w)^2 + \frac{\lambda}{2}\|w\|_2^2$$

Donde $\lambda > 0$ Parametro regularización

Formulacion matricial

$$J_{reg}(w) = \frac{1}{2}(t - \phi w)^T (t - \phi w) + \frac{\lambda}{2} w^T w$$

Donde:

$t \in \mathbb{R}^{N\times 1}$: Vector de respuesta

$\phi \in \mathbb{R}^{N\times Q}$: Matriz de diseño / Caracteristicas

$w \in \mathbb{R}^{Q\times 1}$: Vector de pesos

$\lambda > 0$: Escalar de regularización

Solución Cerrada:

Expandimos el primer termino de error Cuadratico

$$J_{reg}(w) = \frac{1}{2} t^T t - w^T \phi^T t + \frac{1}{2} w^T \phi^T \phi w + \frac{\lambda}{2} w^T w$$

Calculo del gradiente respecto a w

$$\nabla_w (w^T \phi^T t) = \phi^T t$$

$$\nabla_w \left(\frac{1}{2} w^T \phi^T \phi w\right) = \phi^T \phi w$$

$$\nabla_w \left(\frac{\lambda}{2} w^T w\right) = \lambda I_Q w = \lambda w \quad (\text{Donde } I_Q \in \mathbb{R}^{Q\times Q} \text{ es la}$$

matriz Identidad)

$$\nabla_w J_{reg}(w) = \Phi^T \Phi w - \Phi^T t + \lambda w$$

Factorizando el Vector de pesos w

$$\nabla_w J_{reg}(w) = (\Phi^T \Phi + \lambda I_Q) w - \Phi^T t$$

$$\nabla_w J_{reg}(w) = 0_Q \qquad 0_Q \in \mathbb{R}^{Q \times 1}$$

$$(\Phi^T \Phi + \lambda I_Q) w - \Phi^T t = 0_Q$$

$$(\Phi^T \Phi + \lambda I_Q) w = \Phi^T t$$

Solucion Forma Cerrada

$\lambda > 0$ y $\Phi^T \Phi$ es semi-definida positiva

Siempre es invertible incluso si $N < Q$ o $\Phi^T \Phi$ es Singular

$$\hat{w}_{reg} = (\Phi^T \Phi + \lambda I_Q)^{-1} \Phi^T t$$

$(Q \times N)(N \times Q)$ $(Q \times Q)$ $Q \times Q$ $(Q \times N)(N \times 1)$ $(Q \times 1)$

$(Q \times Q)$ $(Q \times 1)$

$(Q \times 1)$

1.3 estimacion por maxima Verosimilitud

Consideramos

$$t_n = \phi(x_n)^T w + \eta_n$$

Donde η_n iid $\eta_n \sim N(0, \sigma_\eta^2)$

Dado que x_n y w son determinstas o fijos t_n es una transformacion lineal

$$t_n | x_n, w, \sigma_\eta^2 \sim N(\phi(x_n)^T w, \sigma_\eta^2)$$

funcion de densidad de probabilidad para una sola observación es:

$$p(t_n | x_n, w, \sigma_n^2) = \frac{1}{\sqrt{2\pi\sigma_n^2}} \exp\left(-\frac{(t_n - \phi(x_n)^T w)^2}{2\sigma_n^2}\right)$$

funcion de Verosimilitud

Dado que la N observaciones $\{(x_n, t_n)\}_{n=1}^N$ no dependen de los parametros w y σ_n^2

$$L(w, \sigma_n^2) = p(t | \phi, w, \sigma_n^2)$$

Se expresa asi

$$p(t | \phi, w, \sigma_n^2) = \prod_{n=1}^{N} p(t_n | x_n, w, \sigma^2_n)$$

Sustituyendo la densidad gaussiana

$$p(t|\phi, w, \sigma_n^2) = \prod_{n=1}^{N} \left(\frac{1}{(2\pi\sigma_n^2)^{1/2}} \exp\left(-\frac{(t_n - \phi(x)^T w)^2}{2\sigma^2_n} \right) \right.$$

Agrupando el producto de potencias y exponenciales

$$p(t|\phi, w, \sigma_n^2) = (2\pi\sigma_n^2)^{-N/2} \exp\left(-\frac{1}{2} \sum_{n=1}^{N} (t_n - \phi(x_n)^T w)^2 \right)$$

En Forma Matricial

$$p(t|\phi, w, \sigma^2_n) = (2\pi\sigma_n^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_n^2} (t - \phi w)^T (t - \phi w) \right.$$

* Construccion del logaritmo de la Verosimilitud

$$\ln p(t|\phi, w, \sigma_n^2) =$$
$$= \ln \left[(2\pi\sigma^2_n)^{-N/2} \exp\left(-\frac{1}{2\sigma_n^2} (t - \phi w)^T (t - \phi w) \right) \right]$$

Por Propiedades del logaritmo

$$\ln(a \cdot b) = \ln a + \ln b$$

$$\ln(a^b) = b \ln a$$

$$\ln p(t|\phi, w, \sigma_n^2) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma_n^2) - \ldots$$
$$\ldots - \frac{1}{2\sigma_n^2} (t - \phi w)^T (t - \phi w)$$

* Obtención del estimador de Pesos por maxima Verosimilitud ($\hat{w}_{MLE}$)

Queremos encontrar el Vector w que maximice el logaritmo de Verosimilitud

$$\hat{w}_{MLE} = \arg\max_{w} \ln p(t \mid \phi, w, \sigma_n^2)$$

Observamos que los primeros dos terminos $\left(-\frac{N}{2}\ln(2\pi) \text{ y } -\frac{N}{2}\ln(\sigma_n^2)\right)$ no dependen de w por lo que actuan Como Constantes

Ademas Como $\sigma_n^2 > 0$, el factor $-\frac{1}{2\sigma_n^2}$ es negativo

maximizar este logaritmo es equivalente a minimizar la parte Cuadratica residual

$$\arg\max_{w}\left[-\frac{1}{2\sigma_n^2}(t-\phi w)^T(t-\phi w)\right]$$

$$\Updownarrow$$

$$\arg\min_{w}\left[\frac{1}{2}(t-\phi w)^T(t-\phi w)\right]$$

Deduccion del gradiente

Calculamos el gradiente del log- Verosimilitud respecto a w e igualamos a cero 0_2

$$\nabla_w \ln p(t \mid \phi, w, \sigma^2) = -\frac{1}{2\sigma_n^2}(2\phi^T t + 2\phi^T\phi w)$$

$$= \frac{1}{\sigma_n^2}(\phi^T t + \phi^T\phi w)$$

Igualando a 0_Q

$$\frac{1}{\sigma^2 n}(\Phi^T t - \Phi^T \Phi w) = 0_Q$$

$$\Phi^T \Phi w = \Phi^T t$$

Si $\Phi^T \Phi$ es invertible

$$\boxed{w_{MLE} = (\Phi^T \Phi)^{-1} \Phi^T t}$$

El estimador de mínimos cuadrados y el de máxima verosimilitud son matemáticamente idénticos:

la minimización de los errores al cuadrado no es una ocurrencia casual; es la forma directa y matemática de decir que confiamos en que el ruido a las fallas de nuestras mediciones se comportan como una campana normal (Gaussiana) centrada en cero.

1.4 Máximo a Posteriori (MAP)

* Marco probabilístico Bayesianos y Supuestos

En la estimación MAP tratamos al vector de pesos w como una variable aleatoria en lugar de un parametro fijo desconocido.

Incorporamos información previa sobre w a traves de una distribución a priori Gausiana centrada en cero

$$w \sim N(0_Q, \sigma_w^2 I_Q$$

Su función de densidad de probabilidad a priori es

$$p(w) = \frac{1}{(2\pi\sigma_w^2)^{Q/2}} \exp\left(-\frac{1}{2\sigma_w^2} w^T w\right)$$

$$P(t|\phi, w, \sigma_n^2) = (2\pi\sigma_n^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_n^2}(t-\phi w)^T(t-\phi w)\right)$$

* Aplicacion de la regla de Bayes y Distribución a posteriori

$$P(w|t, \phi, \sigma_n^2, \sigma_w^2) = \frac{P(t|\phi, w, \sigma_n^2)\, P(w)}{\underbrace{P(t|\phi, \sigma_n^2, \sigma_w^2)}_{Cte}}$$

$$P(w|t, \phi, \sigma_n^2, \sigma_w^2) \propto p(t|\phi, w, \sigma_n^2)\, P(w)$$

* Deducción del problema de optimización MAP

El estimador MAP busca el valor de w que maximiza la densidad de probabilidad a posteriori:

$$\hat{w}_{MAP} = \arg\max_w p(w|t, \phi, \sigma_n^2, \sigma_w^2)$$

$$= \arg\max_w \left[\ln p(t|\phi, w, \sigma_n^2) + \ln p(w)\right]$$

Log - Verosimilitud

$$\ln p(t|\phi, w, \sigma_n^2) = -\frac{N}{2}\ln(2\pi\sigma_n^2) - \frac{1}{2\sigma_n^2}(t-\phi w)^T(t-\phi w)$$

Log - Prior

$$\ln p(w) = -\frac{Q}{2}\ln(2\pi\sigma_w^2) - \frac{1}{2\sigma_w^2} w^T w$$

Sumando ambas expresiones

$$\ln(p(w\mid t,\phi)) = \underbrace{-\frac{N}{2}\ln(2\pi\sigma_n^2)}_{\text{Cte}} \underbrace{-\frac{Q}{2}\ln(2\pi\sigma_w^2)}_{\text{Cte}} - \dots$$

$$\dots - \frac{1}{2\sigma_n^2}(t-\phi w)^T(t-\phi w) - \frac{1}{2\sigma_w^2} w^T w$$

$$\arg\max_w \left[-\frac{1}{2\sigma_n^2}(t-\phi w)^T(t-\phi w) - \frac{1}{2\sigma_w^2} w^T w \right] \times \sigma_n^2$$

$$\Updownarrow$$

$$\arg\min_w \left[\frac{1}{2}(t-\phi w)^T(t-\phi w) + \frac{\sigma_n^2}{2\sigma_w^2} w^T w \right]$$

* Derivación de la Solución Cerrada de $\hat{w}_{MAP}$

Sea $J_{MAP}(w)$ la función objetivo equivalente a minimizar

$$J_{MAP}(w) = \frac{1}{2}(t-\phi w)^T(t-\phi w) + \frac{\sigma_n^2}{2\sigma_w^2} w^T w$$

$$J_{MAP}(w) = \frac{1}{2}(t^T - w^T\phi^T)(t-\phi w) + \frac{\sigma_n^2}{2\sigma_n^2} w^T w$$

$$J_{MAP}(w) = \frac{1}{2}(t^T t - t^T\phi w - w^T\phi^T t + w^T\phi^T\phi w)$$

$$+\frac{\sigma_n^2}{2\sigma_w^2} w^T w$$

$$J_{MAP}(w) = \frac{1}{2} t^T t - w^T\phi^T t + \frac{1}{2} w^T\phi^T\phi w + \frac{\sigma_n^2}{2\sigma_w^2} w^T w$$

$$\nabla_w J_{MAP}(w) = 0 - \Phi^T t + \Phi^T \Phi w + \frac{\sigma_n^2}{\sigma_w^2} w = 0$$

$$\left(\Phi^T \Phi + \frac{\sigma_n^2}{\sigma_w}\right) w = \Phi^T t$$

$$\hat{w}_{MAP} = \left(\Phi^T \Phi + \frac{\sigma_n^2}{\sigma_w^2} I_Q\right)^{-1} \Phi^T t$$

al comparar la Solucion MAP Con la Solucion obtenida Por minimos Cuadrados regularizados Se deduce la equivalencia matematica exacta entre el enFoque bayesiano (MAP) y el enFoque Frecuentista

El mapa de Caracteristicas Se define Como

$$\phi : X \longrightarrow \mathcal{H}_K \qquad \phi(x) = K(x, \cdot)$$

Definicion formal y Rigurosa

Sea X una Variable aleatoria definida Sobre el espacio $\mathcal{X}$ Con distribucion de Probabilidad P_X

$$X \sim P_X$$

El embedding de media de X en $\mathcal{H}_K$ denotado Como

$$\mu_K(X) \quad o \quad \mu P_X \quad \Leftarrow \text{ esperanza de la evaluacion del kernel}$$

$$\mu_K = E_{X \sim P_X}[K(X, \cdot)] = \int_X K(X, \cdot)\, \partial P_X(x) \in \mathcal{H}_K$$

Reglas a Cumplir Para que $\mu_K \in \mathcal{H}_K$

μ_K sea finita

utilizando la Propiedad reproductora y desigualdad de Jensen

la norma de $\phi(x) = K(x, \cdot)$ en $\mathcal{H}_K$

$$\|\phi(x)\| = \sqrt{\langle K(x, \cdot), K(x, \cdot) \rangle_{H_K}} = \sqrt{K(x, x)}$$

Para la esperanza de Bochener $E[K(X, \cdot)]$ exista en H_K exigimos la Propiedad de integrabilidad

$$E_{X \sim P_X}\left[\sqrt{K(X, X)}\right] = \int_X \sqrt{K(x, x)}\, \partial P(x) < \infty$$

Si $K(x, x) = 1$ Se Cumple la condicion $E_{X \sim P_X}\left[\sqrt{K(x, x)}\right] < \infty$

Para Cualquier distribucion P_X

Teorema de representacion de Riesz y Propiedad reproductora RKHS

Para Cualquie funcion $f \in \mathcal{H}_K$ el producto interno entre f y el embedding de media μ_K es igual al $E_{X \sim P_X}[f(X)]$

$$\langle f, \mu_K \rangle_{\mathcal{H}_K} = \langle f, E_X[K(X, \cdot)] \rangle_{\mathcal{H}_K} = E_X[\langle f, K(X, \cdot) \rangle_{\mathcal{H}_K}] = E_{X \sim P_X}[f(X)]$$

2.2 Pertenencia a $\mathcal{H}_K$ e interpretación geométrica del embedding de media

Explicar por qué $\mu_K \in \mathcal{H}_K$

$\mu_K = \mathbb{E}_{X \sim P_X}[K(X, \cdot)]$ sea un elemto bien definido en $\mathcal{H}_K$

Se debe garantizar que su norma en $\mathcal{H}_K$ sea finita

$$\|\mu_K\|_{\mathcal{H}_K} < \infty$$

$$\|\mu_K\|^2 = \langle \mu_K, \mu_K \rangle_{\mathcal{H}_K}$$

$$\mu_K = \mathbb{E}_X[K(X, \cdot)]$$

$$\|\mu_K\|^2 = \langle \mathbb{E}_X[K(X, \cdot)], \mathbb{E}_X[K(X', \cdot)] \rangle_{\mathcal{H}_K}$$

X' es iid de X

- intercambiamos la esperanza y el producto interno (por linealidad de ambos operadores):

$$\|\mu_K\|^2_{\mathcal{H}_K} = \mathbb{E}_{X \sim P_X} \mathbb{E}_{X' \sim P_X}[\langle K(X, \cdot), K(X', \cdot) \rangle_{\mathcal{H}_K}]$$

Aplicando la propiedad reproductora

$X, X' \in \mathcal{X}$:

$$\langle K(X, \cdot), K(X', \cdot) \rangle_{\mathcal{H}_K} = K(X, X')$$

$$\|\mu_K\|^2_{\mathcal{H}_K} = \mathbb{E}_{X, X'}[K(X, X')] = \int_{\mathcal{X}} \int_{\mathcal{X}} K(X, X') \, dP_X(X) \, dP_X(X')$$

Aplicando la desigualdad de Cauchy

$$K(x,x') = \langle \phi(x), \phi(x') \rangle_{H_K} \leq \|\phi(x)\|_{H_K} \|\phi(x')\|_{H_K}$$
$$= \sqrt{K(x,x)} \, , \sqrt{K(x')(x')}$$

$$\|\mu_K\|_{H_K} \leq E_{x \sim P_X}\left[\sqrt{K(x,x)}\right]$$

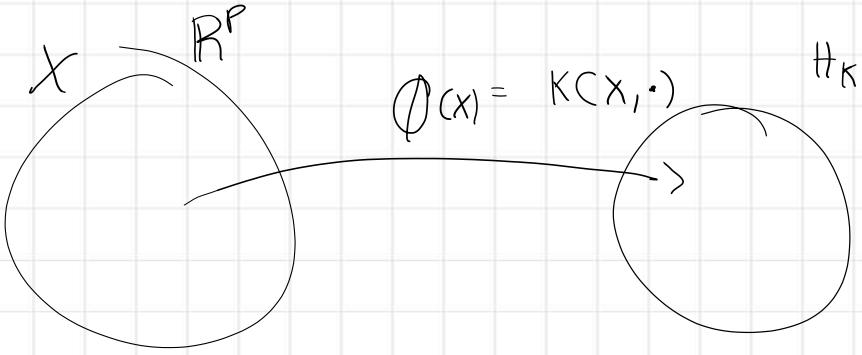
Si $E[\sqrt{x,x}] < \infty$ entonces $\|\mu_K\|_{H_K}$ es finita

$$\mu_K \in H_K$$

Representacion geometrica

Por ejemplo

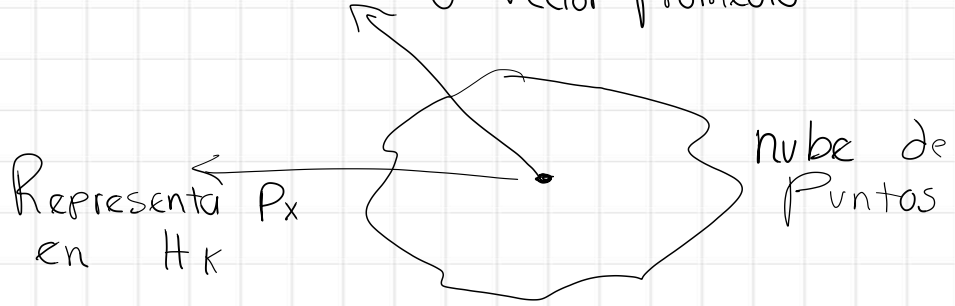
$X = \mathbb{R}^p \sim P_X$ tiene un $P(x)$ función de densidad



Dimensión muy alta

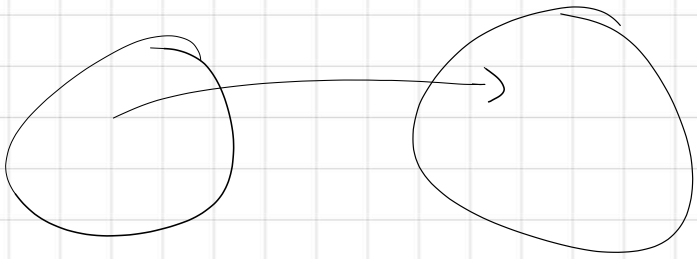
Dato individual → Vector/función

μ_K = Centro masa o Vector Promedio



Inyectividad del Embedding y Kernels Característico

$P_X \rightarrow \mu_K$ es inyectiva



Función/Vector

Captura todos los momentos de distribución

μ, σ^2, asimetría, Curtosis, etc

Ej P_X y P_Y Son iguales si Sus μ_X y μ_Y Coinciden Como Puntos/funciones en H_K

$$P_X = P_Y \iff \mu_X = \mu_Y \text{ en } H_K$$

2.3 Demostracion del estimador Emperico Sesgado de la Discrepancia maxima de Medias

$(\widehat{MMD_b^2})$

Sea $X \sim P_X$ $\quad$ VA1 $\rightarrow X$

$Y \sim P_Y$

Con $\mu_X = E[k(X, \cdot)]$

$\mu_Y = E[k(Y, \cdot)]$ $\quad \in H_k$

la distancia Cuadratica poblacional es

$$MMD^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{H_k}$$

$$= \langle \mu_X - \mu_Y, \mu_X - \mu_Y \rangle_{H_k}$$

$$= \langle \mu_X, \mu_X \rangle_{H_k} + \langle \mu_Y, \mu_Y \rangle_{H_k} - 2\langle \mu_X, \mu_Y \rangle_{H_k}$$

Por Propiedad reproductora

$$\langle \mu_X, \mu_X \rangle = E_{X,X'}[k(X, X')]$$

$$\langle \mu_Y, \mu_Y \rangle = E_{Y,Y'}[k(Y, Y')]$$

$$\langle \mu_X, \mu_Y \rangle = E_{X,Y}[k(X, Y)]$$

Por lo tanto

$$MMD^2(P_X, P_Y) = E_{X,X'}[k(X, X')] + E_{Y,Y'}[k(Y, Y')] - 2E_{X,Y}[k(X, Y)]$$

Paso a la Versión Empirica (Muestral)

Dado que no Conocemos las distribuciones exactas P_X y P_Y

Contamos con dos muestras independientes

$\{x_i\}_{i=1}^{n} \sim P_X$ (n observaciones)

$\{y_j\}_{j=1}^{m} \sim P_Y$ (m observaciones)

Remplazamos los embeddings empiricos (promedios muestrales de las Caracteristicas):

$$\hat{\mu}_X = \frac{1}{n}\sum_{i=1}^{n} K(x_i, \cdot) = \frac{1}{n}\sum_{i=1}^{n} \phi(x_i)$$

$$\hat{\mu}_Y = \frac{1}{m}\sum_{j=1}^{n} K(y_j, \cdot) = \frac{1}{m}\sum_{j=1}^{n} \phi(y_j)$$

Sustituyendo $\hat{\mu}_X$ y $\hat{\mu}_Y$ en la norma al cuadrado RKHS

obtenemos el estimador empirico sesgado $\widehat{MMD}_b^2$:

$$\widehat{MMD}_b^2 = \|\hat{\mu}_X - \hat{\mu}_Y\|_{H_K}^2 = \langle \hat{\mu}_X, \hat{\mu}_X \rangle_{H_K} + \langle \hat{\mu}_X, \hat{\mu}_Y \rangle_{H_K} - 2\langle \hat{\mu}_X, \hat{\mu}_Y \rangle_{H_K}$$

Desarrollamos cada uno de los tres terminos muestrales usando Sumatorias y la propiedad reproductora

$$\langle K(x_i, \cdot), K(x_i', \cdot) \rangle_{H_K} = K(x_i, x_i')$$

1 Primer termino ($\hat{\mu}_X$ con $\hat{\mu}_X$)

$$\langle \hat{\mu}_X\ \hat{\mu}_X \rangle_{H_K} = \left\langle \frac{1}{n}\sum_{i=1}^{n} K(x_i, \cdot),\ \frac{1}{n}\sum_{i'=1}^{n} K(x_{i'}, \cdot) \right\rangle$$

$$= \frac{1}{n^2} \sum_{i=1}^{n} \sum_{i'=1}^{n} K(x_i, x_{i'})$$

2 Segundo termino ($\hat{\mu}_X$ con $\hat{\mu}_Y$)

$$\langle \hat{\mu}_Y, \hat{\mu}_Y \rangle_{H_K} = \left\langle \frac{1}{m} \sum_{j=1}^{m} K(y_j, \cdot), \frac{1}{m} \sum_{j'=1}^{m} K(y_{j'}, \cdot) \right\rangle_{H_K}$$

$$= \frac{1}{m^2} \sum_{j=1}^{m} \sum_{j'=1}^{m} K(y_j, y_{j'})$$

3 Tercer termicon ($\hat{\mu}_X$ con $\hat{\mu}_Y$)

$$\langle \hat{\mu}_X, \hat{\mu}_Y \rangle_{HK} = \left\langle \frac{1}{n} \sum_{i=1}^{n} K(x_i, \cdot), \frac{1}{m} \sum_{j=1}^{n} K(y_j, \cdot) \right\rangle$$

$$= \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{n} K(x_i, y_j)$$

Forma Matricial

$K_{XX} \in \mathbb{R}^{n \times n}$, Con entradas $[K_{XX}]_{ii'} = K(x_i, x_{i'})$

$K_{YY} \in \mathbb{R}^{m \times m}$ Con entradas $[K_{YY}]_{jj'} = K(y_j, y_{j'})$

$K_{XY} \in \mathbb{R}^{n \times m}$ Con entradas $[K_{XY}]_{ij} = K(x_i, y_j)$

$1_n \in \mathbb{R}^{n \times 1}$
$1_m \in \mathbb{R}^{m \times 1}$

- $\sum_{i=1}^{n} \sum_{i'=1}^{n} K(x_i, x_{i'}) = 1_n^T K_{XX} 1_n$
- $\sum_{j=1}^{n} \sum_{j'=} K(y_j, y_{j'}) = 1_m^T K_{YY} 1_m$
- $\sum_{i=1}^{n} \sum_{j=1}^{n} K(x_i, y_j) = 1_n^T K_{XY} 1_m$

$$\widehat{MMD}_b^2 = \frac{1}{n^2} 1_n^T K_{xx} 1_n + \frac{1}{m^2} 1_m^T K_{yy} 1_m - \frac{2}{nm} 1_n^T K_{xy} 1_m$$

Dimenciones $(1\times n)(n\times n)(n\times 1)$ $(1\times n)(n\times 1)$ (1×1)

$(1\times m)(m\times m)(m\times 1)$ (1×1)

$(1\times n)(n\times m)(m\times 1)$ (1×1)

Diferencia entre estimador Sesgado y Formulacion Poblacional

- Formulacion poblacional MMD^2 : Valor teorico fijo basado en las Verdaderas distribuciones Continuas o desconocidas P_x y P_y mediante integrales / esperanzas Complejas
- Estimador Sesgado ($\widehat{MMD}_b^2$) : Cantidad Computable a partir de datos discretos finitos

Se llama Sesgado porque incluye los terminos donde $i = i'$ la diagonal de la matris K_{xx} donde $k(x_i, x_i)$ Compara un Punto Consigo mismo.

Punto 3 : Indice de Correlación de Pearson : Espacio original y RKHS

punto 3.1

Sea x, y Variables aleatorias escalares con Varianzas positivas se dispone de un Conjunto N observaciónes

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} \in \mathbb{R}^{N\times 1}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} \in \mathbb{R}^{N\times 1}$$

Sus medias muestrales Son:

$$\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i = \frac{1}{N} 1_N^T x \qquad 1_N \in \mathbb{R}^{N\times 1}$$

$$\bar{y} = \frac{1}{N}\sum_{i=1}^{N} y_i = \frac{1}{N} 1_N^T y$$

El coeficiente de Correlación lineal de pearson

$$\hat{\rho}_{xx} = \frac{\sum_{i=1}^{N}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\left(\sum_{i=1}^{N}(x_i-\bar{x}_2)^2\right)\left(\sum_{i=1}^{N}(y_i-\bar{y})^2\right)}}$$

* Construccion de la Matriz de Centrado (H)

$H \in \mathbb{R}^{N\times N}$

$$H = I_N - \frac{1}{N} 1_N 1_N^T$$

Propiedades fundamentales de H

1) Acción Centrado Sobre un Vector

$$Hx = \left(I_N - \frac{1}{N} 1_N 1_N^T\right)x = x - 1_N\left(\frac{1}{N} 1_N^T x\right) = x - \bar{X} 1_N$$

$$= \begin{bmatrix} x_1 - \bar{x} \\ x_2 - \bar{x} \\ \vdots \\ x_N - \bar{x} \end{bmatrix}$$

Hx Vector de desvios Centrados respecto a la media

2) Simetria

$$H^T = \left(I_N - \frac{1}{N} 1_N 1_N^T\right)^T = I_N^T - \frac{1}{N}\left(1_N 1_N^T\right)^T = I_N - \frac{1}{N} 1_N 1_N^T = H$$

3. Proyector Ortogonal

$$H^2 = H \cdot H = \left(I_N - \frac{1}{N} 1_N 1_N^T\right)\left(I_N - \frac{1}{N} 1_N 1_N^T\right)$$

$$H^2 = I_N - \frac{2}{N} 1_N 1_N^T + \frac{1}{N^2} 1_N \underbrace{\left(1_N^T 1_N\right)}_{N} 1_N^T$$

$$= I_N - \frac{2}{N} 1_N 1_N^T + \frac{1}{N} 1_N 1_N^T = H$$

* Demostración de la formulacion Matricial

A) Transformacion del numerador (covarianzas)

Se expresa la Suma de productos Cruzados Centrados

$$\sum_{i=1}^{N} (x_i - \bar{x})(y_i - \bar{y}) = (x - \bar{x} 1_N)^T (y - \bar{y} 1_N)$$

$$\sum_{i=1}^{N} (x_i - \bar{x})(y_i - \bar{y}) = H(x)^T H(y) = X^T H^T H y$$

Por Propiedades $= X^T H H y$

$= X^T H^2 y = X^T H y$

B) Transformacion del Denominador (varianzas)

$$\sum_{i=1}^{N} (x_i - \bar{x})^2 = (Hx)^T (Hx) = x^T H^T H x = x^T H x$$

$$\sum_{i=1}^{N} (y_i - \bar{y})^2 = (Hy)^T (Hy) = y^T H^T H = y^T H y$$

c) Sustitucion Final

$$\hat{\rho}_{XY} = \frac{x^T H y}{\sqrt{(x^T H x)(y^T H y)}}$$

$x, y \in \mathbb{R}^{N \times 1}$

$H \in \mathbb{R}^{N \times N}$

Numerador $x^T H y$

$(1 \times N)(N \times N)$

$(1 \times N)$

Denominador $x^T H x$

$(1 \times N)\ (N \times N)$

$(1 \times N)$

$\hat{\rho}_{XY}$ = escalar adimensional $[-1, 1]$

3.2

Tenemos 2 Variables aleatorias Vectoriales $X \in \mathbb{R}^P$ y $Y \in \mathbb{R}^Q$ disponemos de N observaciones emparejadas

Sus respectivas Matrices de Gram (o matrices Kernel) Son $K_X, K_Y \in \mathbb{R}^{N \times N}$

La matriz de Centrado $H \in \mathbb{R}^{N \times N}$ Se define Como

$$H = I_N - \frac{1}{N} 1 1^T$$

Donde I_N es la matriz identidad de Orden $N \times N$ y $1 \in \mathbb{R}^N$ en un Vector de unos

Propiedades Clave de la matriz Centrado H

1) Simetria $H^T = H$

2) Idepotencia $H^2 = H \cdot H = H$

3) Propiedad Ciclica de la Traza : para Cualesquiera Matrices A, B de dimensiones Compatibles, $tr(AB) = tr(BA)$

Las matrices de Gram Centradas estan dadas por

$$K_{X,c} = H K_X H \quad ; \quad K_{Y,c} = H K_Y H$$

Producto interno normalizado y expresión en trazas

El alineamiento de Kernels (o Correlacion Matricial RKHS)

Se define fundamentalmente Como el producto interno normalizado entre las dos matrices de Gram Centradas

$K_{X,c}$ y $K_{Y,c}$ bajo el producto interno de frobenius $\langle \cdot, \cdot \rangle_F$:

$$\rho_{RKHS} = C(K_X, K_Y) = \frac{\langle K_{X,c}, K_{Y,c} \rangle_F}{\| K_{X,c} \|_F \| K_{Y,c} \|_F}$$

* Expresión del producto interno en trazas y Sumatorias

Para dos matrices Cuadradas $A, B \in \mathbb{R}^{N \times N}$, el producto interno de Frobenius en terminos de Sumatorias y de traza es

$$\langle A, B \rangle_F = \sum_{i=1}^{N} \sum_{j=1}^{N} A_{ij}, B_{ij} = tr(A^T B)$$

Dado que K_X, K_Y y H Son Simetricas, la Matrices K_{X_c} y $K_{Y,c}$ tambien Son Simetricas

$$K_{X_c}^T = (H K_X H)^T = H^T K_X^T H^T = H K_X H = K_{X,c}$$

Por lo tanto el numerador del alineamiento expresado en trazas es

$$\langle K_{X,c}, K_{Y,c} \rangle_F = tr(K_{X,c}^T, K_{Y,c}) = tr(K_{X,c}, K_{Y,c})$$

Sustituyendo $K_{X,c} = H K_X H$

$$K_{Y,c} = H K_Y H$$

$$\langle K_{Xc}, K_{Yc} \rangle = tr((H K_X H)(H K_Y H))$$

Sabiendo que $H^2 = H$

$$\langle K_{X,c}, K_{Y,c} \rangle_F = tr(H K_X H K_Y H)$$

Por propiedad ciclica de la traza

$$tr(H K_X H K_Y H) = tr(K_X H K_Y H^2) = tr(K_X H K_Y H)$$

Expresion de las normas en el denominador

la norma de frabenius de define Como

$$\|K_{X,c}\|_F = \sqrt{\langle K_{X,c}, K_{X,c}\rangle_F} = \sqrt{tr(K^2_{X,c})}$$

Sustituyendo $K_{X,c} = HK_XH$

$$tr(K^2_{X,c}) = tr((HK_XH)(HK_XH))$$

$$= tr(K_X HK_X H) = \sqrt{tr(K_X HK_X H)}$$

De manera analoga par Y:

$$\|K_{Y,c}\|_F = \sqrt{\langle K_{Y,c}, K_{Y,c}\rangle_F} = \sqrt{tr(K^2_{Y,c})}$$

$$tr(K^2_{Y,c}) = tr((HK_{X,c})(HK_{X,c}))$$

$$\|K_{X,c}\| = \sqrt{tr(K_Y H K_Y H)}$$

* Sustitución y resultado del Alineamiento Centrado

Sustituyendo

$$\rho_{RKHS}(K_X, K_Y) = \frac{tr(K_X H K_Y H)}{\sqrt{tr(K_X HK_X H)\, tr(K_Y HK_Y H)}}$$

* Dimensiones

$X \in \mathbb{R}^{N\times P}$ (N muestras, P Caracteristicas)

$Y \in \mathbb{R}^{N\times Q}$ (N muestras, Q caracteristicas)

$K_X \in \mathbb{R}^{N\times N}$

$K_Y \in \mathbb{R}^{N\times N}$

$H = I_N - \frac{1}{N} 1_{N\times 1}\, 1^T_{1\times N} \in \mathbb{R}^{N\times N}$

$(K_X H K_X H) \in \mathbb{R}^{N \times N}$

$tr(\cdot)$ Mapea una matriz $\in \mathbb{R}^{N \times N}$ a un numero $\in \mathbb{R}^{1 \times 1}$

$\rho_{RKHS}(K_X, K_Y) \in \mathbb{R}$ escalar adimencional en $[-1, 1]$

$\circ [0, 1]$ para Kernels positivos]

* Demostracion para Kernels Lineales $P = Q = 1$

Supongamos Vectores de datos unidimencionales

$(P = Q = 1)$

$x = \{x_1, x_2, \ldots, x_N\}^T \in \mathbb{R}^N$

$y = \{y_1, y_2, \ldots, y_N\}^T \in \mathbb{R}^N$

Para Kernel Lineal, la Matrices Gram Corresponden al Producto externo

$$K_X = X X^T \qquad K_Y = Y Y^T$$

Definimos los Vectores Centrados Como

$$X_c = HX, \quad Y_c = HY$$

Resultandonos una matriz de gram Centrada resulta Ser

$$K_{X,c} = H(XX^T)H = H(X)(X^T)H = X_c X_c^T$$

$$K_{Y,c} = H(YY^T)H = H(Y)(Y^T)H = Y_c Y_c^T$$

miramos el Numerador:

- $tr(K_X K_Y H) = tr(HX_c \; HY_c)$

$$= tr((X_c X_c^T)(Y_c Y_c^T))$$

Por Propiedad Ciclica de la traza

$$tr(X_c (X_c^T Y_c) Y_c^T) = (X_c^T Y_c) \cdot tr(X_c X_c^T)$$

$$= (X_c^T Y_c) \cdot (X_c X_c^T)$$

$$= (X_c^T Y_c)^2$$

Evaluacion del Denominador

$$tr(K_X H K_X H) = tr((X_c, X_c^T)(X_c, X_c^T)) = (X_c^T \cdot X_c) = \|X_c\|_2^4$$

$$tr(K_Y H K_Y H) = tr((Y_c, Y_c^T)(Y_c, Y_c^T)) = (Y_c^T Y_c) = \|Y_c\|_2^4$$

Ahora tomamos la raiz Cuadrada del producto de los denominadores

$$\sqrt{(X_c^T X_c)^2 (Y_c^T Y_c)^2} = (X_c^T X_c)(Y_c^T Y_c) = \|X_c\|_2^2 \|Y_c\|_2^2$$

* Relacion Con el Coficiente de Correlacion de Pearson ($\hat{\rho}_{XY}$)

- $$\hat{\rho}_{XY} = \frac{X_c^T Y_c}{\|X_c\|_2 \|Y_c\|_2}$$

Elevando al Cuadrado la Correlación de Pearson

$$\hat{\rho}^2_{XY} = \frac{(X_c^T Y_c)^2}{\|X_c\|_2^2 \|Y_c\|_2^2}$$

$$\rho(Kx, Kx) = \frac{(X_c^T Y_c)^2}{\|X_c\|_2^2 \, \|Y_c\|_2^2} = \hat{\rho}_{XY}$$

Perdida del signo

Simetria Kernel = miden Similitud no direccional entre Pares de muestra $K(X_i, Y_j) = \langle \phi(X_i), \phi(X_j) \rangle$

Dado que representa Matrices Simetricas Semi-definidas Positivas no trasmiten la nocion de direccion

* Cuadratura Algebraica

El producto Matricial de frobenius $tr(K_{X_c} K_{Y_c})$

los terminos Se Conbinan Como $(X_c^T Y_c)^2$ al elevar al Cuadrado el signo Siempre es +