Taller de aprendizaje de maquinas

Nombres: Anderson Tapie
Alexis Valencia

Punto 1 Clasificacion Lineal y algoritmo del perceptron

Un Clasificador para observaciones $x \in \mathbb{R}^2$ con etiquetas $y \in \{-1; +1\}$ Cuya prediccion se obtiene mediante

$$\hat{y} = \begin{cases} +1, & w^T x + b > 0 \\ -1, & w^T x + b \leq 0 \end{cases} \qquad w \in \mathbb{R}^2 \quad b \in \mathbb{R}$$

1.1) Frontera desicion

Sea $w = [1,2]^T$ y $b = -3$. Obtenga la ecuacion de la recta $w^T x + b = 0$ dibujela e indique la clase asignada a $x_1 = (0,0)$, $x_2 = (1,0)$, $x_3 = (2,1)$ y $x_4 (3,1)$ Justificar Cada Prediccion

Ecuacion de la recta:

$$w^T x + b = 0 \qquad w = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \qquad b = -3$$

$$[1,2] \begin{bmatrix} x^{(1)} \\ x^{(2)} \end{bmatrix} + (-3) = 0$$

$$x^{(1)} + 2x^{(2)} - 3 = 0$$

asumiendo que $x^{(1)}$ Variable horizontal
$x^{(2)}$ Variable Vertical

Despejamos $x^{(2)}$

$$x^{(2)} = \frac{3}{2} - \frac{x^{(1)}}{2}$$

$$x^{(2)} = -\frac{1}{2} x^{(1)} + \frac{3}{2}$$

Corte Con el eje $x^{(2)}$ Cuando $x^{(1)} = 0$

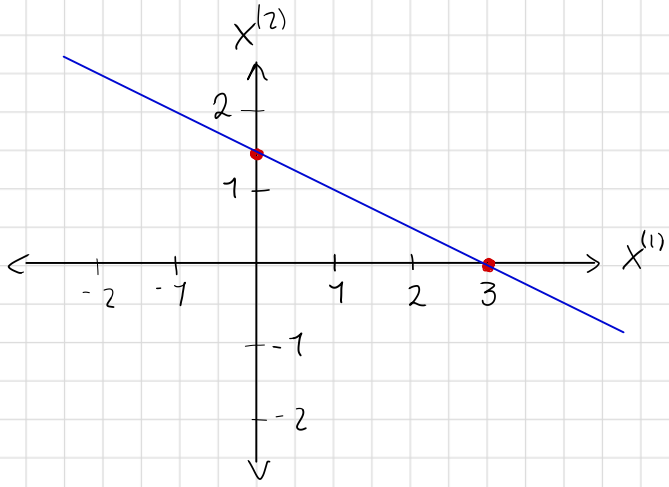
$$x_2 = = \frac{3}{2} = 1.5 \qquad \text{Punto } (0, 1.5)$$

Corte Con el eje $x^{(1)}$ Cuando $x^{(2)} = 0$

$$0 = -\frac{1}{2} x^{(1)} + \frac{3}{2}$$

$$\frac{-\frac{3}{2}}{-\frac{1}{2}} = x^{(1)} \Rightarrow x^{(1)} = 3 \qquad \text{Punto } (3, 0)$$

Graficamos



Ahora evaluamos y clasificamos los puntos dados

Aplicamos la funcion $f(x_i) = w^T x_i + b$

$$\hat{y} = \begin{cases} +1, & f(x) > 0 \\ -1, & f(x) \leq 0 \end{cases}$$

* Para (0,0)

$f(x_1) = 1(0) + 2(0) - 3 = -3$

$f(x_1) = -3 \leq 0$ el punto esta debajo izquierda de la Frontera $\hat{y} = -1$

* Para (1,0)

$f(x_2) = 1(1) + 2(0) - 3 = -2$

$f(x_2) = -2 \leq 0$ el punto esta debajo izquierda de la Frontera $\hat{y} = -1$

* Para (2,1)

$f(x_3) = 1(2) + (2)(1) - 3 = +1$

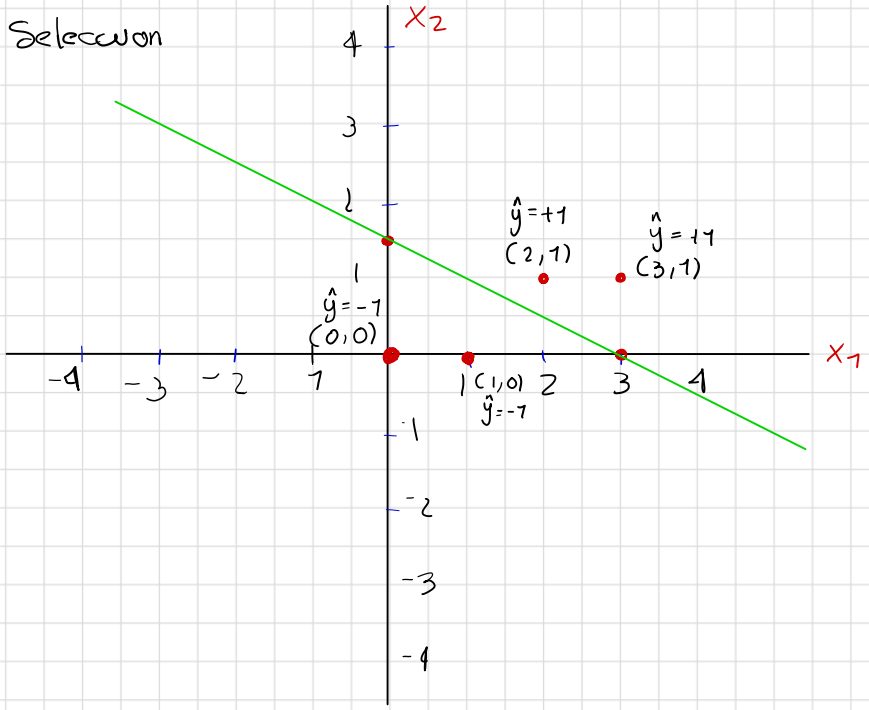
$f(x_3) = +1 > 0$ el punto esta en la region Superior derecha $\hat{y} = +1$

* Para el punto (3,1)

$f(x_4) = 1(3) + (2)(1) - 3 = +2$

$f(x_4) = +2$ el punto esta en la region Superior derecha $\hat{y} = +1$

Grafica de Seleccion



1.2) Actualizacion del perceptrón

Cuando una observación (x_i, y_i) esta mal clasificada Considere la regla

$$w_{nuevo} = w + \eta\, y_i x_i, \quad b_{nuevo} = b + \eta y_i \quad \eta > 0$$

Defina el margen de la observación como

$m_i = y_i (w^T x_i + b)$ y demuestre que inmediatamente despues de aplicar la actualizacion sobre la misma observación

$$w_{nuevo} = m_i + \eta (\|x_i\|_2^2 + 1)$$

Explique brevemente que implica este resultado para la observación corregida

Desarrollo

Definicion del nuevo margen

$$m_{inuevo} = y_i (w^T_{nuevo} x_i + b_{nuevo})$$

$$m_{i\,nuevo} = y_i ((w + \eta y_i x_i)^T x_i + (b + \eta y_i))$$

$$m_{i\,nuevo} = y_i (w^T x_i + \eta y_i x_i^T x_i + b + \eta y_i)$$

$$m_{i\,nuevo} = y_i ((w^T x_i + b) + \eta y_i (1 + x_i^T x_i))$$

$$m_{i\,nuevo} = y_i (w^T x_i + b) + \eta y_i^2 (1 + x_i^T x_i)$$

$y_i (w^T x_i + b)$ → Margen de Observacion m_i

$x_i^T x_i$ → $\|x_i\|_2^2$

$$y_i^2 = (+1)^2 = (-1)^2 = +1 \qquad y_i \in \{-1, 1\}$$

$$m_{i\,nuevo} = m_i + \eta(+1)(1 + \|x_i\|_2^2)$$

$$\boxed{m_{i\,nuevo} = m_i + \eta(\|x_i\|_2^2 + 1)}$$

Interpretacion

Garantia de incremento: tasa de aprendizaje $\eta > 0$

$\|x_i\|_2^2 \geq 0 \rightarrow (\|x_i\|_2^2 + 1)$ Siempre es mayor a cero

$$m_{i\,nuevo} > m_i$$

1.3) Ejercicio numerico

Con $w = [0,0]^T$, $b = 0$, $\eta = 0.5$ $x = [2,1]^T$ y $y = +1$

determine si corresponde actualizar los parametros usando la regla de prediccion dada. Debe ser asi, Cualcule los nuevos w, b y margen

Evaluar la predicción actual

Calculamos el valor de la función del perceptrón con los parametros iniciales

$$w^T x + b = [0,0]\begin{bmatrix}2\\1\end{bmatrix} + 0.0 = (0.2 + 0.1) + 0.0 = 0$$

$$\hat{y} = \begin{cases} +1 & \text{si } w^T x + b > 0 \\ -1 & \text{si } w^T x + b \leq 0 \end{cases}$$

$$w^T x + b = 0.0 \leq 0$$

$$\hat{y} = -1$$

Paso 2: ¿Corresponde actualizar?

Etiqueta real (y): $+1$

Predicción del modelo ($\hat{y}$) : -1

Dado que $y \neq \hat{y}$ el modelo ha cometido un error

el margen inicial es $m = y(w^T x + b) = (+1)(0) = 0 \leq 0$

Corresponde actualizar los parametros

$$w_{nuevo} = w + \eta y x$$

$$w_{nuevo} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 0.5\,(+1) \cdot \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 1.0 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 1.0 \\ 0.5 \end{bmatrix}$$

2. Nuevo Sesgo (b_{nuevo})

$$b_{nuevo} = b + \eta y$$

$$b_{nuevo} = 0.0 + 0.5\,(+1) = 0.5$$

Calculo del nuevo margen (m_{nuevo})

Via A :

$$m_{nuevo} = y\,(w^T_{nuevo} x + b_{nuevo})$$

$$w^T_{nuevo} x = \begin{bmatrix} 1.0 & 0.5 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = (1.0 \cdot 2) + (0.5 \cdot 1)$$

$$= 2.0 + 0.5 = 2.5$$

$$m_{nuevo} = (+1)\,(2.5 + 0.5) = \boxed{+3.0}$$

Correccion del perceptrón

$$m_{nuevo} = m_{anterior} + \eta(\|x\|_2^2 + 1)$$

1. $m_{anterior} = y(w^T x + b) = 0$
2. $\|x\|_2^2 = 2^2 + 1^2 = 4 + 1 = 5$

$$m_{nuevo} = 0 + 0.5 \cdot (5 + 1) = 0.5 \cdot 6 = \boxed{+3.0}$$

Punto (2) clasificacion por los K vecinos mas cercanos (K-NN)

Concidere una observacion nueva $q = (1, 1)$ y el siguiente conjunto de entrenamiento:

observación	x_1	x_2	x_3	x_4	x_5
x_i	(0,0)	(1,0)	(3,1)	(0,3)	(1,1 ; 1,1)
clase	A	A	B	B	B

Use la distancia euclidiana $d(q, x_i) = \sqrt{(q_1 - x_{i1})^2 + (q_2 - x_{i2})^2}$ y la votacion mayoritaria de los K vecinos mas próximos

solucion: Calculo manual y clasificacion de $q = (1, 1)$

dado el punto de consulta $q = (1, 1)$ y el conjunto de entrenamiento x_1, x_2, x_3, x_4, x_5, Se utiliza la distancia euclidiana bidimensional $d(q, x_i) = \sqrt{(q_1 - x_{i1})^2 + (q_2 - x_{i2})^2}$

calculo de distancias a mano

distancia d $x_1 = (0,0)$ (clase A)

$d(q\ x_1) = \sqrt{(1-0)^2 + (1-0)^2} = \sqrt{1^2 + 1^2} = \sqrt{2} \approx 1,4142$

distancia a $x_2 = (1,0)$ (clase A)

$d(q, x_2) = \sqrt{(1-1)^2 + (1-0)^2} = \sqrt{0^2 + 1^2} = \sqrt{1} = 1$

distancia a $x_3 = (3,1)$ (clase B)

$d(q, x_3) = \sqrt{(1-3)^2 + (1-1)^2} = \sqrt{(-2)^2 + 0^2} = \sqrt{4} = 2$

distancia a $x_4 = (0,3)$ (clase B)

$d(q, x_4) = \sqrt{(1-0)^2 + (1-3)^2} = \sqrt{1^2 + (-2)^2} = \sqrt{5} \approx 2,2361$

distancia a $x_5 = (1,1)$ (clase B)

$d(q, x_5) = \sqrt{(1-1)^2 + (1-1)^2} = \sqrt{0} = 0$

Ordenamiento de observaciones por cercanía

Ordenando las observaciones desde la menor hasta la mayor distancia respecto a q:

orden	observacion(x_i)	coordenadas	Distancia $d(q,x)$	clase
1	x_5	(1, 1)	0	B
2	x_2	(1, 0)	1	A
3	x_1	(0, 0)	$\sqrt{2}$	A
4	x_3	(3, 1)	2	B
5	x_4	(0, 3)	$\sqrt{5}$	B

Clasificacion segun el valor de K

Para $K = 1$:

- Se concidera unicamente el primer vecino mas cercano: $x_5 = (1, 1)$ con distancia 0
- clase de $x_5 = B$
- Prediccion $\hat{y}_q (K=1)$: clase B

Para $K = 3$

- Se consideran 3 vecinos mas cercanos $\{x_5, x_2, x_1\}$
- clase A 2 votos (x_2 y x_1)
- clase B 1 voto (x_5)
- Por votacion mayoritaria, la clase A supera a la clase B (2 > 1)
- Prediccion $\hat{y}_q (K=3)$: Clase A

Para $K = 5 = \{x_5, x_2, x_1, x_3, x_4\}$

- tomamos los 5 Vecinos del dataset
- votos clase A: 2 (x_2, x_1), clase B (x_5, x_3, x_4)
- Prediccion $\hat{y}_q$: clase B

¿Por qué el valor de k cambia la prediccion?

El hiper parametro K controla el nivel de resolucion o escala espacial en el que el modelo toma decisiones.

- Escala ultra-local ($K=1$): el modelo evalua unicamente el punto inmediatamente mas proximo. debido a que el punto de consulta $q = (1, 1)$ coincide exactamente en posicion con la observacion de entrenamiento x_5 la distancia es cero y se asigna su clase B

- Escala regional ($k=3$): Al aplicar el radio de busqueda a 3 vecinos el algoritmo contempla la densidad local circundante. Dado que en las cercanias inmediatas a q predominan puntos de la clase A (x_1, x_2) la votacion mayoritaria cambia la prediccion hacia la clase A
- Escala global ($k=5$) Al expandir la Busqueda al data set completo el sesgo de la muestra total predomina. Dado que el data set de entrenamiento tiene una mayor proporcion general de elementos de la clase B (3 de 5 datos), la prediccion retorna a la clase B

Punto ③ Evaluacion de un clasificador Binaria

Dado el conjunto de etiquetas verdaderas y y sus predicciones $\hat{y}$

$$y = [0,0,0,0,1,1,1,1,1,1] \quad \hat{y} = [0,1,0,0,1,0,1,1,0,1]$$

Tomando la clase 1 como positiva y la clase 0 como negativa

Matriz de Confusion e Identificacion de TP, TN, FP, FN

Para identificar los acierto y errores, se realiza una comparacion posicion por posición entre cada etiqueta real y_i y su correspondiente prediccion $\hat{y}_i$

- Verdaderos Positivos (TP): $y_i = 1$ y $\hat{y}_i = 1$. Se presenta en los indices 5, 7, 8 y 10 $TP = 4$
- Verdaderos Negativos (TN): $y_i = 0$ y $\hat{y}_i = 0$ se presentan en los indices 1, 3 y 4 $TN = 3$
- Falsos Positivos (FP): $y_i = 0$, $\hat{y}_i = 1$. Se presenta en el indice 2 $FP = 1$
- Falsos Negativos (FN): $y_i = 1$ y $\hat{y}_i = 0$ Se presenta en los indices 6 y 9 $FN = 2$

Matriz de Confusion Tabulada

Con las filas representando las clases reales y las columnas las clases

Predichas

		Clase Predicha ($\hat{y}$)	
		Predicho 0 (Negativo)	Predicho 1 (Positivo)
Caso real (y)	Real 0 (Negativo)	$TN = 3$	$FP = 1$
Caso real (y)	Real 1 (Positivo)	$FN = 2$	$TP = 4$

Calculo Manual de Metricas y Explicacion Conceptualmente

Justituyendo los valores obtenidos ($TP = 4$, $TN = 3$, $FP = 1$, $FN = 2$) en cada una de las ecuaciones planteadas

Exactitud (Accuracy)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{4+3}{4+3+1+2} = \frac{7}{10} = 0,70 \ (70,0\%)$$

¿Que evalua?: Mide la proporción total de predicciones correctas (tanto positivas como negativas) respecto al total de observacion evaluadas

Sensibilidad / Exhaustividad (Recall):

$$Recall = \frac{TP}{TP + FN} = \frac{4}{4+2} = \frac{4}{6} = \frac{2}{3} \approx 0,6667 \ (66,67\%)$$

¿Que evalua? Mide la capacidad del modelo para identificar correctamente los casos que realmente pertenecen a la clase positiva (evitar falsos negativos)

Precision

$$Precision = \frac{TP}{TP + FP} = \frac{4}{4+1} = \frac{4}{5} = 0,80 \ (80,0\%)$$

Mide que proporcion de las observaciones que el modelo clasifico como positivas evan verdaderamente positivas (evitar falsos positivos)

Puntaje F1 (F1-Score)

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision \cdot Recall} = \frac{2\,(0,80)\,(0,6667)}{0,80 + 0,6667} = \frac{1,0667}{1,4667} \approx 0,7273 \ (72,73\%)$$

Esta es una medida armonica entre la Precision y el Recall
Proporciona una medida balanceada de desempeño siendo
especialmente util cuando existe un desbalance de clases o se
requiere un compromiso entre evitar falsos positivos y falsos negativos